Volatility Regimes and Forecasting Performance

Команда: Минькевич Виталий (Йа один!!!)

1. Постановка задачи и ревью статей

Проект посвящён изучению влияния режимов волатильности финансового рынка на точность прогнозирования временных рядов.

Гипотеза исследования:

Прогнозная точность моделей ухудшается в периоды высокой волатильности, а модели, учитывающие гетероскедастичность (например, GJR-GARCH), проявляют большую устойчивость к смене рыночных режимов, чем ML и DL модели.

Другими словами, задача проекта — понять, насколько чувствительны различные подходы к прогнозированию (статистические/эконометрические модели, машинное обучение и нейронные сети) к изменениям рыночной динамики, и выявить, какие модели обеспечивают стабильные прогнозы независимо от текущего уровня волатильности.

Описание литературы:

Волатильность финансовых рынков известна своей **нестационарностью и кластеризацией**. В классической работе The Econometrics of Financial Markets описано, что рынки часто переживают периоды высокой и низкой волатильности, и эти периоды существенно влияют на риск и доходность активов.

Современные исследования показывают, что традиционные модели прогнозирования цен, которые игнорируют изменения волатильности, часто демонстрируют ухудшение точности в периоды сильных колебаний. Например, Engle (1982) показал, что условная гетероскедастичность может быть эффективно смоделирована с помощью GARCH-подходов, что позволяет учесть нестабильность дисперсии доходностей.

Статистические модели, такие как ARIMA или простые наивные подходы, предполагают стационарность и линейность временного ряда. Так же, есть предположение о постоянстве второго момента. В условиях изменяющейся волатильности их прогнозы часто становятся менее точными. Наивные модели, например, используют последнее наблюдение, что делает их чувствительными к резким колебаниям рынка.

Машинное обучение, включая модели градиентного бустинга и случайного леса, способно захватывать нелинейные зависимости и взаимодействия между признаками.

Исследования Feng et al. 2020 показывают, что ML-модели могут улучшать точность прогнозов в периоды средней волатильности, однако их производительность также снижается в экстремальных условиях, если они не обучены на данных с разнообразными рыночными режимами.

Глубокие нейронные сети (MLP, LSTM) предлагают возможность моделировать сложные нелинейные паттерны и временные зависимости. LSTM, например, хорошо справляется с захватом долгосрочной памяти ряда. Однако Fischer & Krauss 2018 отмечают, что такие модели чувствительны к недостатку данных и шуму в высоко волатильные периоды. MLP, будучи менее сложной архитектурой, зачастую демонстрирует большую стабильность, но не учитывает временную структуру напрямую, что может ограничивать её точность на финансовых временных рядах.

Модели GARCH и их расширения (например, GJR-GARCH) специально разрабатывались для учета **гетероскедастичности**, то есть изменения дисперсии доходностей с течением времени. Исследования Glosten, Jagannathan & Runkle 1993 показывают, что такие модели способны сохранять точность прогнозов даже в периоды высокой волатильности, так как они напрямую моделируют динамику изменчивости рынка.

Таким образом, сочетание GARCH-подходов с ML или нейронными сетями может дать **более устойчивый прогноз**, чем использование одной из этих методик в чистом виде.

Существующие исследования подчеркивают:

1. Зависимость прогнозной точности от рыночного режима.
2. Преимущество моделей, в которых учитывается волатильность, в последствии этого, модели показывают лучший результат в пиковые моменты.
3. Ограничения стандартных ML и DL моделей при высоких колебаниях, если они не включают признаки волатильности или регрессию на прошлую дисперсию.

Тем не менее, **сравнительный анализ разных подходов в единой экспериментальной среде с явным разделением на high/low volatility regimes** встречается редко. Наш проект заполняет этот пробел, объединяя статистические, ML и DL методы и оценивая их устойчивость к смене режимов на одном и том же наборе финансовых временных рядов (S&P500 и EUR/USD).

2. Данные

Используются следующие временные ряды с ежедневной частотой:

- **S&P500 (^GSPC)**
- **EUR/USD (EURUSD=X)**

Период: с января 2023 до декабря 2025 года.

Источники данных: Yahoo Finance (через библиотеку yfinance).

Мотивация конкретного выбора активов:

В большеснтве своем, каждый актив может моделироватся по разному и с разными подходами, и для разных целей. С одной стороны, у нас есть подход из финансовой математики, где мы запускаем монте карло для броуновского движения или любых других процессов (с прыжками, кусочно заданными и прочими вещами) и говорим, что среднее всех путей – это и есть цена актива в момент T. Это идеально подходит для прайсинга деривативов. Тем не менее, задача может стоять иначе – о causality, или расчет VAR портфелей (где классический эконометрические плдходы) в полне работают.

Я выбирал два разных актива по своей экономической интуции, так как на данные активы могут влиять свои экономические шоки. Условный рынок equity больше влияет sp500, а рынок ставок fx/rates на бивалютную корзину.

Графики САМОЙ ЦЕНЫ (СПОТА):

Предобработка

1. Рассчитываются **логарифмические доходности** (лог-доходности).

2. Применяется **скользящая волатильность** с окном 20 дней.
3. На основе медианной волатильности выделяются два режима на тестовой выборке:

- high_vol — высокая волатильность, выше медианы
- low_vol — низкая волатильность, ниже медианы

Графики ВОЛАТИЛЬНОСТИ (нашего таргета):

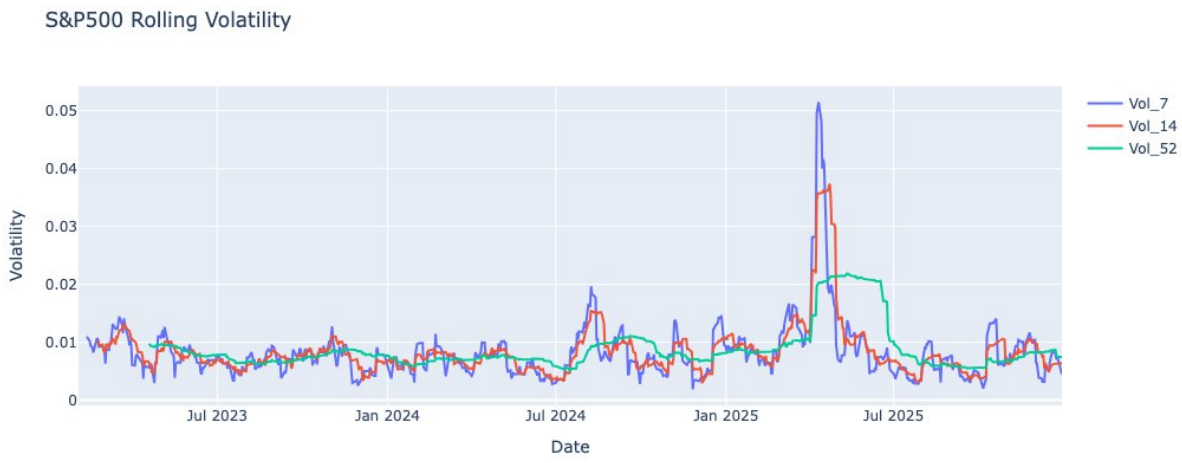

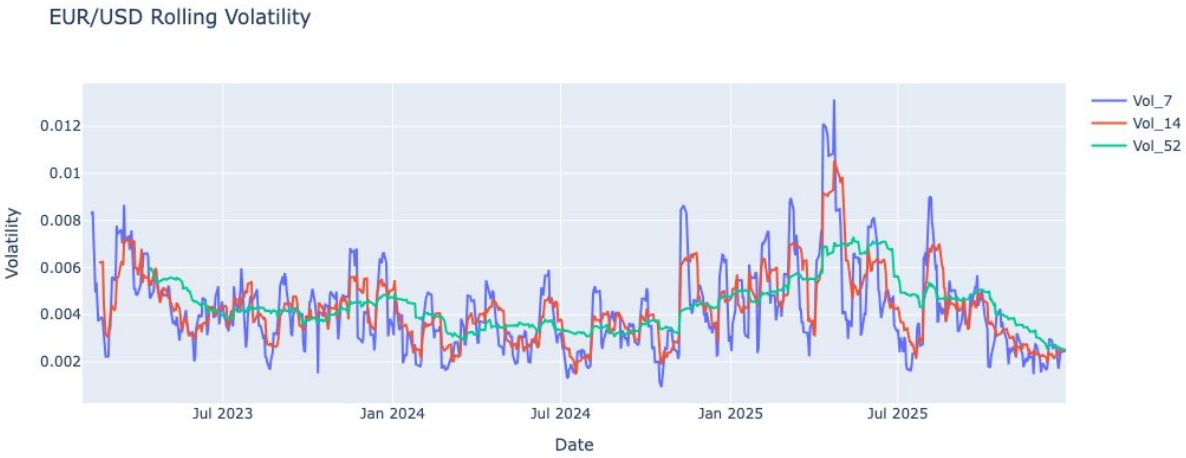

Проверка стационарности

Для лог-доходностей был проведён ADF-тест:

Использую ADF тест. Локально тестировал KPSS так же

Актив	ADF Statistic	p-value	Ряд стационарен?
S&P500	-15.46032	0.0	Да
EUR/USD	-28.21253	0.0	Да

Результаты подтверждают стационарность доходностей, что важно для корректного применения моделей прогнозирования.

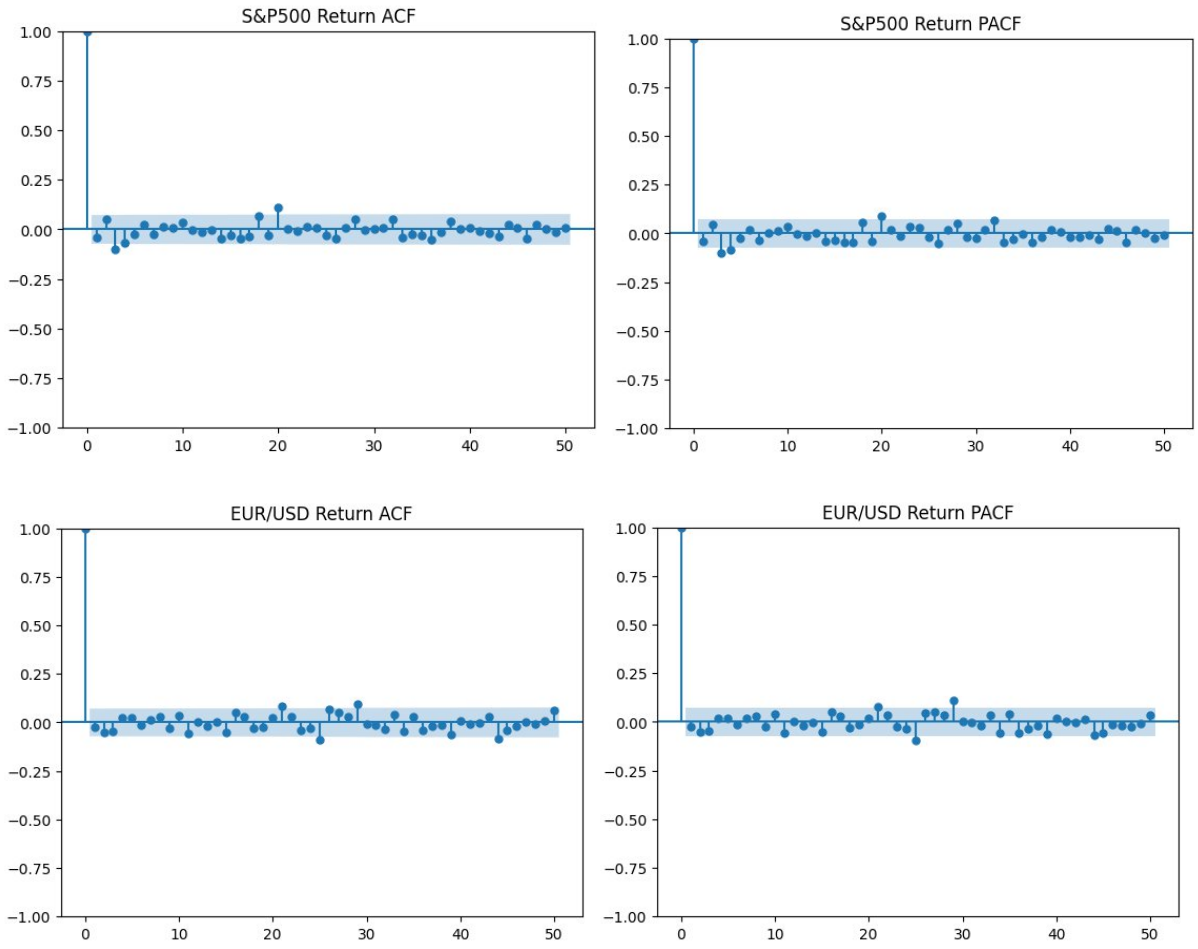

3. Методология эксперимента

Разделение данных на train/test:

- Train: 2023-01-30 — 2024-12-31
- Test: 2025-01-02 — 2025-12-30

Модели для прогнозирования:

- **Статистическая/эконометрическая:**
  - Naive (последнее наблюдение) – попробовал так же MA(7), MA(14), MA(28) и такие же медианы, но решил взять прям совсем наивный вариант.
  - GJR-GARCH (учёт волатильности и асимметрии) – модель из garch-семейства
- **Machine Learning:**
  - XGBoost (градиентный бустинг, 10 признаков)
- **Deep Learning:**
  - MLP Regressor (CPU-версия, простая нейронная сеть) – брал самый легкий вариант, так как тестировал запуски локально в проекте, в коллабе не совсем удобно. Так бы взял из torch что-то, условно хайповый TFT трансформер или простенькую LSTM/GRU. Но, давайте считать что это Extensions))))

Обучение и Тест:

- Модели обучались на train.
- Валидацинный период для подбора гиперпараметров я намеренно пропускаю
- На тестовом периоде формировались прогнозы, которые сравнивались с фактическими значениями.

Оценка качества прогнозов по режимам:
Метрики рассчитывались отдельно для low_vol и high_vol:

- RMSE
- MAE
- Directional Accuracy
- Дельта = Ошибка_high_vol – Ошибка_low_vol

Сравнение моделей:

Анализ проводился по устойчивости метрик к смене режима волатильности и общей точности прогнозов.

4. Результаты эксперимента

4.1 EUR/USD

Модель	RMSE Low Vol	RMSE High Vol	Δ RMSE	MAE Low Vol	MAE High Vol	Δ MAE	Dir. Accuracy Low	Dir. Accuracy High
Naive	0.00487	0.00872	0.00385	0.00362	0.00673	0.00311	0.567	0.453

GJR-GARCH	0.00365	0.00612	0.00247	0.00273	0.00456	0.00183	0.0	0.0
XGBoost	0.00230	0.00428	0.00197	0.00173	0.00309	0.00136	0.797	0.844
MLP	0.00922	0.00875	-0.00047	0.00833	0.00702	-0.00131	0.492	0.477

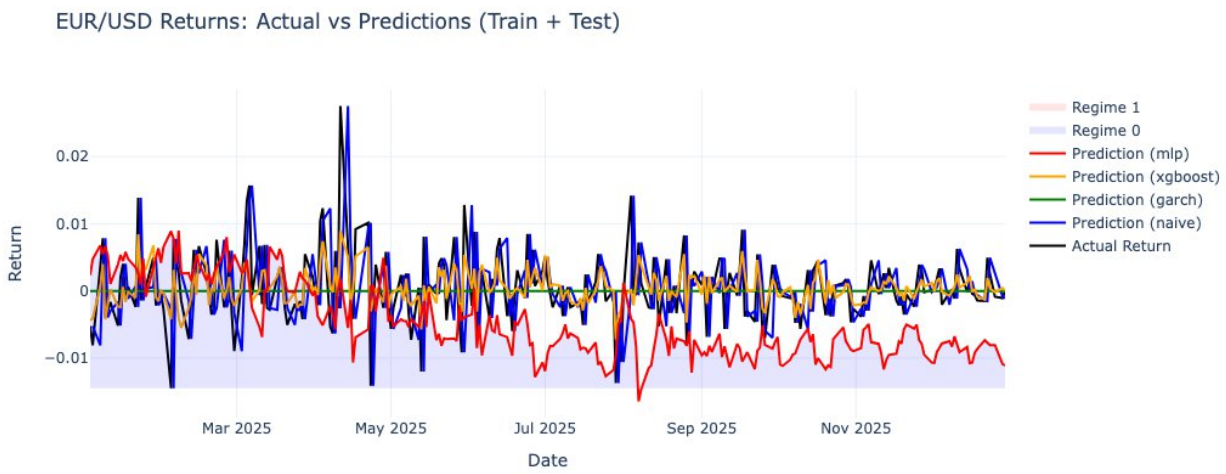

4.2 S&P500

Модель	RMSE Low Vol	RMSE High Vol	Δ RMSE	MAE Low Vol	MAE High Vol	Δ MAE	Dir. Accuracy Low	Dir. Accuracy High
Naive	0.01017	0.02262	0.01246	0.00742	0.01468	0.00725	0.520	0.480
GJR-GARCH	0.00670	0.01523	0.00853	0.00496	0.00974	0.00478	0.0	0.0
XGBoost	0.00374	0.01189	0.00815	0.00273	0.00662	0.00388	0.808	0.798
MLP	0.26336	0.20078	-0.06259	0.25833	0.18028	-0.07805	0.440	0.403

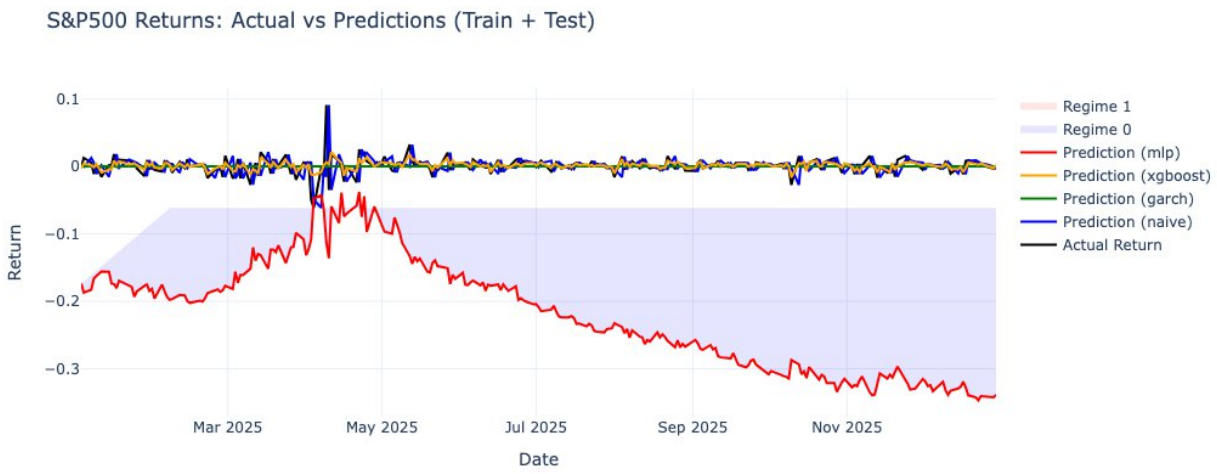

5. Анализ результатов

1. **EUR/USD:**
   - XGBoost показывает **лучшую точность** и **высокую устойчивость к смене режима**.
   - GJR-GARCH также стабилен, особенно по дельта метрик.
   - Naive модель уступает по точности, но обеспечивает простоту и базовую ориентацию.
   - MLP переобучается, демонстрируя нестабильность и низкую directional accuracy. Так же, наихудшие результаты по метрика точности.
1. **S&P500:**
   - XGBoost сохраняет высокую точность на обоих режимах.
   - GJR-GARCH демонстрирует устойчивость, уменьшает рост ошибок при высокой волатильности.
   - MLP демонстрирует крайне высокие ошибки на low_vol, что говорит о необходимости масштабирования и ретрейна.
   - Дельта метрик показывает, что GARCH и XGBoost меньше всего подвержены влиянию смены режима.

1. **Общий вывод:**
   - Модели, учитывающие волатильность или использующие бустинг, более стабильны, и подходят для практических задач. Бустинг может учитывать большое кол-во экзогенных признаков, и лучше объяснять ошибку, тем не менее, нет явного свойства статистической интрепритации. В свою очередь, garch-семейство или любые другие эконометрчиеские модели – способны это делать, но в ошибке может сидеть много эндогенности неучтенной.
   - Простые модели (Naive, MLP без дообучения) плохо адаптируются к изменяющейся волатильности. Предпологаю, что хорошо затюнинная TFT показывала бы

сравнительный результат с плохо затюниным бустингом. Но точно лучше, чем MLP из sklearn.

- Волатильность напрямую влияет на RMSE и MAE: высокий режим увеличивает ошибки, кроме случаев, когда модель специально учитывает этот эффект.

6. Выводы

1. Режимы волатильности существенно влияют на качество прогнозов.
2. Для EUR/USD и S&P500 наилучшая устойчивость и точность у XGBoost и GJR-GARCH.
3. Простая наивная модель пригодна для базовой оценки и low_vol периода, но не стабильно работает при высокой волатильности.
4. MLP без дополнительной настройки и ретрейна не подходит для прогнозирования активов с высокой изменчивостью.
5. Метрики дельта позволяют оценить чувствительность моделей к смене рыночных условий — чем меньше Δ, тем модель стабильнее.

Рекомендации:

- Для практических финансовых прогнозов использовать XGBoost или GJR-GARCH.
- MLP стоит применять только после тщательной предобработки данных и ретрейна на последних наблюдениях.
- Следующий шаг: построение прогноза на 3 месяца вперёд с визуализацией будущих значений и оценкой стабильности моделей.

7. Extensions

- Замена MLP на Torch варианты
- Валидацинный период с тюнингом гиперпараметров для каждой из моделей
- Другие способы разбиения и поиски/кластеризацию периодов высокой и низкой волатильности
- Поиск стартовой точки «взрыва» волательности